

Diseño de una red neuronal para la optimización del posicionamiento de cámaras de videovigilancia en la Alcaldía Gustavo A. Madero, en la Ciudad de México

Carlo Ariel Vargas Hernández, Gilberto Arellano Velázquez,
Dra. María Elena Cruz Meza, M. en C. Gisela González Albarrán
Escuela Superior de Cómputo, I.P.N. México D.F.

Tel. 57-29-6000 ext. 52000 y 52021. E-mail: cvargash1500@alumno.ipn.mx, garellanov0800@egresado.ipn.mx

Resumen—La ubicación estratégica de cámaras de videovigilancia representa un problema relevante para los sistemas de seguridad pública debido a las limitaciones presupuestales y operativas asociadas con la expansión de la infraestructura existente. En este trabajo hizo una propuesta basada en Inteligencia Artificial para identificar regiones prioritarias para la instalación de nuevas cámaras de videovigilancia en la Alcaldía Gustavo A. Madero de la Ciudad de México. Se comparó el desempeño de un Perceptrón Multicapa (MLP) y una Red Neuronal Gráfica (GNN) basada en la arquitectura GraphSAGE utilizando variables geoespaciales, demográficas y delictivas. Los resultados muestran que la GNN genera agrupaciones espaciales más consistentes al incorporar explícitamente las relaciones de vecindad entre regiones urbanas. Además, se desarrolló una plataforma web para visualizar, analizar y exportar las regiones identificadas como prioritarias.

Palabras clave— Redes Neuronales Gráficas, GraphSAGE, Videovigilancia, Seguridad Pública, Análisis Geoespacial, Inteligencia Artificial.

I. INTRODUCCIÓN

La seguridad pública constituye uno de los principales desafíos para las ciudades modernas. La expansión de los sistemas de videovigilancia ha permitido fortalecer las labores de monitoreo y prevención del delito; sin embargo, determinar dónde instalar nuevas cámaras continúa siendo un problema complejo debido a la gran cantidad de variables involucradas.

Los avances recientes en Inteligencia Artificial han permitido desarrollar modelos capaces de identificar patrones espaciales y temporales en grandes volúmenes de información. En particular, las Redes Neuronales Gráficas (Graph Neural Networks, GNN) ofrecen una alternativa para modelar explícitamente las relaciones existentes entre regiones geográficas vecinas.

El objetivo de este trabajo consiste en desarrollar y evaluar un modelo basado en GraphSAGE para identificar regiones prioritarias para la instalación de nuevas cámaras de videovigilancia en la Alcaldía Gustavo A. Madero y comparar su desempeño con un modelo MLP tradicional.

II. METODOLOGÍA

Se utilizó la metodología CRISP-DM para el desarrollo del proyecto. En la primera, segunda y tercera fase de la metodología se obtuvo una cuadrícula geográfica compuesta por 8,681 celdas que cubren la totalidad de la Alcaldía Gustavo A. Madero.

Para cada celda se integró información relacionada con:

- Incidencia delictiva.
- Variables demográficas.
- Infraestructura urbana.
- Variables espaciales derivadas.

Se construyó un conjunto de datos compuesto por 24 variables predictoras. Posteriormente, en la fase cuarta y quinta se modeló la arquitectura de las redes y se entrenaron dos modelos:

1. Perceptrón Multicapa (MLP).
2. Red Neuronal Gráfica basada en GraphSAGE.

Para la GNN se generó un grafo espacial utilizando vecindad tipo Queen, permitiendo que cada región intercambiara información con las celdas adyacentes durante el proceso de aprendizaje. Cada modelo contó con mejoras que se implementaron a lo largo de tres versiones de las redes.

La fase sexta estuvo fuera de alcance, pero, se implementó una aplicación web utilizando Flask, Folium y GeoPandas para visualizar las regiones prioritarias identificadas por ambos modelos.

III. RESULTADOS

Los resultados muestran diferencias importantes entre los modelos evaluados.

III-A. Comparación entre MLP y GraphSAGE

En la primera versión de las redes, como se observa en la Tabla I, el modelo MLP obtuvo una mayor exactitud global (Accuracy). Sin embargo, las métricas más relevantes para la identificación de regiones prioritarias corresponden a Recall, Precision y F1-score debido al desbalance de clases presente en el conjunto de datos.

En este contexto, GraphSAGE superó ampliamente al modelo MLP. Estos resultados indican que la incorporación de relaciones espaciales mediante grafos permite generar predicciones más confiables y consistentes para la identificación de regiones prioritarias.

Respecto a las métricas probabilísticas, GraphSAGE presentó un menor Error Absoluto Medio, aunque registró un RMSE ligeramente superior. En conjunto, los resultados sugieren que la Red Neuronal Gráfica ofrece un mejor equilibrio entre capacidad predictiva y coherencia espacial para el problema estudiado.

Tabla I
COMPARACIÓN DE DESEMPEÑO ENTRE MLP Y GRAPH SAGE

Tipo	Métrica	MLP	GraphSAGE
Clasificación	Accuracy	72.23 %	68.77 %
Clasificación	Recall	62.79 %	68.70 %
Clasificación	Precision	6.59 %	98.10 %
Clasificación	F1-score	11.93 %	80.00 %
Probabilística	MAE	0.368	0.310
Probabilística	RMSE	0.419	0.550

Como se observa en la Fig. 1 el modelo MLP produjo una distribución más dispersa de las regiones prioritarias a lo largo de la alcaldía. Por otro lado, la arquitectura GraphSAGE generó agrupaciones espaciales más compactas y consistentes con la distribución geográfica de los delitos observados.




Figura 1. Comparación de casillas propuestas por el modelo MLP (izquierda) y GNN (derecha).

Para el escenario correspondiente al 5 % de las regiones prioritarias se identificaron 435 celdas, de las cuales 179 fueron coincidentes entre ambos modelos, representando más del 40 % de coincidencia.

En el escenario correspondiente al 20 % de las regiones prioritarias se identificaron 1,737 celdas, observándose una coincidencia de 1,088 regiones, equivalente a más del 60 % del total.

Los resultados muestran que ambos modelos identifican regiones con alta incidencia delictiva; sin embargo, la arquitectura GraphSAGE genera agrupaciones espaciales más compactas debido a la incorporación explícita de relaciones de vecindad. Esto permite que la información de las regiones

Tabla II
COMPARACIÓN ENTRE MLP Y GRAPH SAGE

Característica	MLP	GraphSAGE
Variables utilizadas	24	24
Información espacial explícita	No	Sí
Uso de vecindad Queen	No	Sí
Probabilidad promedio	0.264	0.594
Regiones prioritarias (5 %)	435	435
Coincidencia entre modelos	179 regiones	
Coincidencia relativa	41.1 %	
Regiones prioritarias (20 %)	1737	1737
Coincidencia entre modelos	1088 regiones	
Coincidencia relativa	62.6 %	
Distribución espacial	Dispersa	Agrupada
Coherencia espacial	Media	Alta

adyacentes contribuya al proceso de predicción, favoreciendo una distribución espacial más coherente de las zonas prioritarias.

III-B. Comparación con el Trabajo Terminal 2025-A012

El trabajo anterior fue una aproximación pionera al uso de algoritmos bioinspirados para proponer zonas donde colocar cámaras. La Tabla III resume las principales diferencias entre la propuesta desarrollada en este trabajo y la estrategia basada en algoritmos genéticos presentada en el Trabajo Terminal 2025-A012.

Tabla III
COMPARACIÓN CON EL TT 2025-A012

Métrica	TT 2025-A012 (AG)	TT 2026-A176 (GNN)
Técnica principal	Algoritmo Genético	GraphSAGE + MLP
Paradigma	Optimización	Aprendizaje automático
Tipo de salida	Ubicación óptima de cámaras	Regiones prioritarias
Incorporación explícita de vecindad	No	Sí
Uso de grafos	No	Sí
Tipo de salida	Ubicaciones optimizadas	Probabilidad por celda considerando vecinos
Evaluación	Fitness de 21.5 % para la GAM	F1-Score de 30.17 %

IV. CONCLUSIONES

La incorporación de relaciones espaciales mediante Redes Neuronales Gráficas permitió generar recomendaciones más consistentes para la identificación de regiones prioritarias destinadas a la instalación de nuevas cámaras de videovigilancia.

Los resultados obtenidos sugieren que GraphSAGE aprovecha de manera efectiva la estructura espacial de los datos urbanos al considerar la influencia de las regiones vecinas durante el proceso de aprendizaje.

Asimismo, el sistema desarrollado demuestra el potencial de la Inteligencia Artificial y del análisis geoespacial como herramientas de apoyo para la toma de decisiones en materia de seguridad pública.

Como trabajo futuro se plantea incorporar información temporal de mayor resolución, modelos de atención sobre grafos y estrategias híbridas que combinen técnicas predictivas con métodos de optimización bioinspirados.

AGRADECIMIENTOS

El autor agradece a la Escuela Superior de Cómputo del Instituto Politécnico Nacional y a los directores del Trabajo Terminal por el apoyo brindado durante el desarrollo de esta investigación.

REFERENCIAS

- [1] T. N. Kipf and M. Welling, "Semi-Supervised Classification with Graph Convolutional Networks," International Conference on Learning Representations, 2017.
- [2] W. Hamilton, Z. Ying and J. Leskovec, "Inductive Representation Learning on Large Graphs," Advances in Neural Information Processing Systems, 2017.
- [3] F. Harary, *Graph Theory*, Addison-Wesley, 1969.
- [4] E. Fuentes López & A. Orozco Solorio, *Sistema de optimización para el posicionamiento de nuevas cámaras de vigilancia para ampliar un C2 mediante algoritmos bioinspirados*, ESCUELA SUPERIOR DE CÓMPUTO, 2025.